

二手车价格预测分析报告

本报告围绕二手车成交价格 price 建立回归预测模型，按照需求分析、数据预处理、数据业务分析/可视化分析、算法建模、项目结论五个部分展开。

项目	数值	说明
训练集	150,000 行	31 列
测试集	50,000 行	30 列
清洗后训练集	135,884 行	36 个特征
最佳模型	RandomForest 主模型	MAE=622.53

评价指标： $MAE = (1/n) * \sum(|\text{真实价格} - \text{预测价格}|)$ 。MAE

越小，说明模型预测越准确。

1. 需求分析

任务目标是根据车辆基础属性、交易信息和匿名特征预测二手车价格 price。 price

是连续数值，因此该问题属于监督学习中的回归预测任务。

```
train_raw = pd.read_csv(TRAIN_PATH, dtype=str)
test_raw = pd.read_csv(TEST_PATH, sep=r"\s+", engine="python", dtype=str)
print(train_raw.shape, test_raw.shape)
```

字段组	代表字段	处理方式
SaleID	唯一ID	提交关联，不入模
日期字段	regDate/creatDate	拆解日期并构造车龄
车辆属性	power/kilometer	截断功率并构造组合特征
交易属性	seller/offerType	过滤非法错位值
匿名特征	v_0-v_14	连续变量入模

2. 数据预处理

预处理阶段先统一缺失值表示，再过滤明显字段错位的记录。seller 和 offerType 理论上只应为



0 或 1，出现日期、价格等值时说明该行字段发生偏移。

```
train = train_raw.replace("-", np.nan).copy()
legal_schema = train["seller"].isin(["0", "1"]) & train["offerType"].isin(["0", "1"])
train = train[legal_schema].copy()
train = train.apply(pd.to_numeric, errors="coerce")
train = train[train["price"].notna() & (train["price"] >= 0)]
```



清洗项目	数量
字段错位过滤	14,116
无效价格过滤	0
清洗后训练样本	135,884

字段	缺失数量
notRepairedDamage	17558
v_14	14116
kilometer	4191
v_13	3583
v_12	1469
gearbox	1387

3. 数据业务分析 / 可视化分析



价格呈长尾分布，低价车样本更多；车龄、里程、功率和匿名特征与价格存在不同程度相关性。




4. 算法建模

特征工程保留数值字段，并从日期字段中提取年月日和日期序号，再构造车龄 `car_age_days`

与功率里程比 `power_per_km`。


```
data["car_age_days"] = data["creatDate_ord"] - data["regDate_ord"]
data["power"] = data["power"].clip(0, 600)
data["power_per_km"] = data["power"] / (data["kilometer"] + 1)
```

```
models = {
    "Ridge": Pipeline([("imputer", SimpleImputer()), ("scaler", StandardScaler()),
    ("model", Ridge())]),
    "RandomForest": Pipeline([("imputer", SimpleImputer()), ("model",
    RandomForestRegressor())])
}
```



模型	验证集 MAE
RandomForest 主模型	622.53
Ridge 基线模型	2124.55

特征重要性分析



随机森林的特征重要性显示，匿名特征、车龄相关特征、功率和里程等变量对价格预测贡献较大。由于要从车辆使用年限、行驶里程和动力水平解释价格差异。

5. 项目结论

本项目完成了从原始数据读取、异常清洗、可视化分析、特征工程到模型训练验证的完整流程。

RandomForest 主模型，验证集 MAE 为 622.53。

结论：随机森林比 Ridge 线性基线更适合该数据，因为二手车价格受到车龄、里程、功率、品牌/车型圈征等多因素共同影响，变量之间存在明显非线性关系。后续可尝试

LightGBM/XGBoost、交叉验证、目标对数变换和类别统计特征继续降低 MAE。